


# LE PERCEPTRON

Jérémie Cabessa  
Laboratoire DAVID, UVSQ


# PERCEPTRON

- Le **perceptron** [Rosenblatt, 1957, Rosenblatt, 1958] est un simple neurone qui agit comme un *classifieur binaire*.




# PERCEPTRON

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les *inputs*.
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  et  $b \in \mathbb{R}$  sont les *paramètres*: *poids synaptiques* et *biais*, respectivement.
- ▶  $y \in \{-1, +1\}$  est l'*output* (binaire).
- ▶  $\sigma$  est la *fonction d'activation*.




# PERCEPTRON

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les *inputs*.
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  et  $b \in \mathbb{R}$  sont les *paramètres*: *poids synaptiques* et *biais*, respectivement.
- ▶  $y \in \{-1, +1\}$  est l'*output* (binaire).
- ▶  $\sigma$  est la *fonction d'activation*.




# PERCEPTRON

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les *inputs*.
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  et  $b \in \mathbb{R}$  sont les *paramètres*: *poids synaptiques* et *biais*, respectivement.
- ▶  $y \in \{-1, +1\}$  est l'*output* (binaire).
- ▶  $\sigma$  est la *fonction d'activation*.



## PERCEPTRON

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les *inputs*.
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  et  $b \in \mathbb{R}$  sont les *paramètres*: *poids synaptiques* et *biais*, respectivement.
- ▶  $y \in \{-1, +1\}$  est l'*output* (binaire).
- ▶  $\sigma$  est la *fonction d'activation*.




# PERCEPTRON

- La dynamique du perceptron est la suivante:

$$y = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} +1, & \text{if } \mathbf{w}^T \mathbf{x} + b \geq 0 \\ -1, & \text{if } \mathbf{w}^T \mathbf{x} + b < 0. \end{cases}$$

où  $\mathbf{x} = (x_1, \dots, x_M)$  et  $\mathbf{w} = (w_1, \dots, w_M)$ .




# PERCEPTRON

- Par abus de langage, posons:

$$\mathbf{x} := (1, x_1, \dots, x_M) \text{ et } \mathbf{w} := (b, w_1, \dots, w_M).$$

- La dynamique du perceptron s'écrit alors:

$$y = \sigma(\mathbf{w}^T \mathbf{x}) = \begin{cases} +1, & \text{if } \mathbf{w}^T \mathbf{x} \geq 0 \\ -1, & \text{if } \mathbf{w}^T \mathbf{x} < 0. \end{cases}$$






# PERCEPTRON

- ▶ Par abus de langage, posons:

$$\mathbf{x} := (1, x_1, \dots, x_M) \text{ et } \mathbf{w} := (b, w_1, \dots, w_M).$$

- ▶ La dynamique du perceptron s'écrit alors:

$$y = \sigma(\mathbf{w}^T \mathbf{x}) = \begin{cases} +1, & \text{if } \mathbf{w}^T \mathbf{x} \geq 0 \\ -1, & \text{if } \mathbf{w}^T \mathbf{x} < 0. \end{cases}$$



## REMARQUE

- ▶ Soient  $\mathbf{w} = (b, w_1, \dots, w_M) \in \mathbb{R}^{M+1}$  les paramètres du perceptron.
- ▶ Le vecteur  $\mathbf{w}$  définit un *hyperplan* dans l'espace des inputs  $\mathbb{R}^M$  (en non  $\mathbb{R}^{M+1}$ ) dont l'équation est

$$\mathbf{w}^T \mathbf{x} = 0 \quad \text{i.e.,} \quad \sum_{i=1}^M w_i x_i + b = 0.$$

- ▶  $\mathbf{w}' := (w_1, \dots, w_M)$  est le vecteur normal de cet hyperplan.
- ▶ Par définition, le perceptron de paramètres  $\mathbf{w}$  classe les points de  $\mathbb{R}^M$  de part et d'autre de cet hyperplan.

## REMARQUE

- ▶ Soient  $\mathbf{w} = (b, w_1, \dots, w_M) \in \mathbb{R}^{M+1}$  les paramètres du perceptron.
- ▶ Le vecteur  $\mathbf{w}$  définit un *hyperplan* dans l'espace des inputs  $\mathbb{R}^M$  (en non  $\mathbb{R}^{M+1}$ ) dont l'équation est

$$\mathbf{w}^T \mathbf{x} = 0 \quad \text{i.e.,} \quad \sum_{i=1}^M w_i x_i + b = 0.$$

- ▶  $\mathbf{w}' := (w_1, \dots, w_M)$  est le vecteur normal de cet hyperplan.
- ▶ Par définition, le perceptron de paramètres  $\mathbf{w}$  classe les points de  $\mathbb{R}^M$  de part et d'autre de cet hyperplan.

## REMARQUE

- ▶ Soient  $\mathbf{w} = (b, w_1, \dots, w_M) \in \mathbb{R}^{M+1}$  les paramètres du perceptron.
- ▶ Le vecteur  $\mathbf{w}$  définit un *hyperplan* dans l'espace des inputs  $\mathbb{R}^M$  (en non  $\mathbb{R}^{M+1}$ ) dont l'équation est

$$\mathbf{w}^T \mathbf{x} = 0 \quad \text{i.e.,} \quad \sum_{i=1}^M w_i x_i + b = 0.$$

- ▶  $\mathbf{w}' := (w_1, \dots, w_M)$  est le vecteur normal de cet hyperplan.
- ▶ Par définition, le perceptron de paramètres  $\mathbf{w}$  classe les points de  $\mathbb{R}^M$  de part et d'autre de cet hyperplan.


## REMARQUE

- ▶ Soient  $\mathbf{w} = (b, w_1, \dots, w_M) \in \mathbb{R}^{M+1}$  les paramètres du perceptron.
- ▶ Le vecteur  $\mathbf{w}$  définit un *hyperplan* dans l'espace des inputs  $\mathbb{R}^M$  (en non  $\mathbb{R}^{M+1}$ ) dont l'équation est

$$\mathbf{w}^T \mathbf{x} = 0 \quad \text{i.e.,} \quad \sum_{i=1}^M w_i x_i + b = 0.$$

- ▶  $\mathbf{w}' := (w_1, \dots, w_M)$  est le vecteur normal de cet hyperplan.
- ▶ Par définition, le perceptron de paramètres  $\mathbf{w}$  classe les points de  $\mathbb{R}^M$  de part et d'autre de cet hyperplan.

## REMARQUE



## REMARQUE

- ▶ Si on omet la fonction d'activation  $\sigma$  (ou qu'on prend  $\sigma$  comme étant l'identité), alors la dynamique du perceptron devient

$$y = \mathbf{w}^T \mathbf{x} + b$$

ce qui correspond exactement à une *régression linéaire*.

# ENTRAÎNEMENT (TRAINING)

- Soit un train set

$$\mathcal{S} = \{(\mathbf{x}_k, y_k) \in \mathbb{R}^M \times \{-1, +1\} : k = 1, \dots, K\}.$$

- L'*entraînement* d'un perceptron (*training*) consiste à déterminer (s'ils existent) des poids  $\hat{\mathbf{w}}$  tels que tous les points du train set soient bien classifiés, i.e.:

$$\text{Si } y_k = +1, \text{ alors } \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k) = +1$$

$$\text{Si } y_k = -1, \text{ alors } \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k) = -1$$

- Si les points ne sont pas linéairement séparables, on peut fixer un critère d'arrêt:

$$\frac{1}{K} \sum_{k=1}^K (y_k - \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k)) < \delta.$$



# ENTRAÎNEMENT (TRAINING)

- Soit un train set

$$\mathcal{S} = \{(\mathbf{x}_k, y_k) \in \mathbb{R}^M \times \{-1, +1\} : k = 1, \dots, K\}.$$

- L'*entraînement* d'un perceptron (*training*) consiste à déterminer (s'ils existent) des poids  $\hat{\mathbf{w}}$  tels que tous les points du train set soient bien classifiés, i.e.:

$$\text{Si } y_k = +1, \text{ alors } \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k) = +1$$

$$\text{Si } y_k = -1, \text{ alors } \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k) = -1$$

- Si les points ne sont pas linéairement séparables, on peut fixer un critère d'arrêt:

$$\frac{1}{K} \sum_{k=0}^K (y_k - \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k)) < \delta.$$

# ENTRAÎNEMENT (TRAINING)

- Soit un train set

$$\mathcal{S} = \{(\mathbf{x}_k, y_k) \in \mathbb{R}^M \times \{-1, +1\} : k = 1, \dots, K\}.$$

- L'*entraînement* d'un perceptron (*training*) consiste à déterminer (s'ils existent) des poids  $\hat{\mathbf{w}}$  tels que tous les points du train set soient bien classifiés, i.e.:


$$\text{Si } y_k = +1, \text{ alors } \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k) = +1$$

$$\text{Si } y_k = -1, \text{ alors } \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k) = -1$$

- Si les points ne sont pas linéairement séparables, on peut fixer un critère d'arrêt:

$$\frac{1}{K} \sum_{k=0}^K (y_k - \sigma(\hat{\mathbf{w}}^T \mathbf{x}_k)) < \delta.$$

## ENTRAÎNEMENT (TRAINING)



# ENTRAÎNEMENT (TRAINING)

---

Algorithm 1: Training algorithm of the perceptron

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

```
w := (0, ..., 0, 0) = 0
for e = 1 to nb_epochs do
  for k = 1 to K do
    if  $y_k = -1$  and  $\sigma(w^T x_k) = +1$  then
      w := w -  $x_k$ 
    else if  $y_k = +1$  and  $\sigma(w^T x_k) = -1$  then
      w := w +  $x_k$ 
    end
  end
end
return predictions
```

---

# ENTRAÎNEMENT (TRAINING)

---

Algorithm 1: Training algorithm of the perceptron

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

for  $e = 1$  to  $nb\_epochs$  do

    for  $k = 1$  to  $K$  do

        if  $y_k = -1$  and  $\sigma(\mathbf{w}^T \mathbf{x}_k) = +1$  then

$\mathbf{w} := \mathbf{w} - \mathbf{x}_k$

        else if  $y_k = +1$  and  $\sigma(\mathbf{w}^T \mathbf{x}_k) = -1$  then

$\mathbf{w} := \mathbf{w} + \mathbf{x}_k$

        end

    end

end

return predictions

---

# ENTRAÎNEMENT (TRAINING)

---

Algorithm 1: Training algorithm of the perceptron

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  *to*  $nb\_epochs$  **do**

**for**  $k = 1$  *to*  $K$  **do**

**if**  $y_k = -1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = +1$  **then**

$\mathbf{w} := \mathbf{w} - \mathbf{x}_k$

**else if**  $y_k = +1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = -1$  **then**

$\mathbf{w} := \mathbf{w} + \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---

# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 1:** Training algorithm of the perceptron

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  *to*  $nb\_epochs$  **do**

**for**  $k = 1$  *to*  $K$  **do**

**if**  $y_k = -1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = +1$  **then**

$\mathbf{w} := \mathbf{w} - \mathbf{x}_k$

**else if**  $y_k = +1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = -1$  **then**

$\mathbf{w} := \mathbf{w} + \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---

# ENTRAÎNEMENT (TRAINING)

---

Algorithm 1: Training algorithm of the perceptron

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  *to*  $nb\_epochs$  **do**

**for**  $k = 1$  *to*  $K$  **do**

**if**  $y_k = -1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = +1$  **then**

$\mathbf{w} := \mathbf{w} - \mathbf{x}_k$

**else if**  $y_k = +1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = -1$  **then**

$\mathbf{w} := \mathbf{w} + \mathbf{x}_k$

**end**

**end**

**end**

*return* predictions

---



# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 1:** Training algorithm of the perceptron

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$  $\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$ **for**  $e = 1$  *to*  $nb\_epochs$  **do**    **for**  $k = 1$  *to*  $K$  **do**        **if**  $y_k = -1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = +1$  **then**             $\mathbf{w} := \mathbf{w} - \mathbf{x}_k$         **else if**  $y_k = +1$  *and*  $\sigma(\mathbf{w}^T \mathbf{x}_k) = -1$  **then**             $\mathbf{w} := \mathbf{w} + \mathbf{x}_k$         **end**    **end****end****return** predictions

---

# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 2:** Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

```
 $w := (0, \dots, 0, 0) = \mathbf{0}$ 
for  $e = 1$  to  $nb\_epochs$  do
  for  $k = 1$  to  $K$  do
    if  $y_k \cdot \sigma(w^T x_k) < 0$  then
       $w := w + y_k \cdot x_k$ 
    end
  end
end
return predictions
```

---

- On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $w := w + \gamma \cdot y_k \cdot x_k$

# ENTRAÎNEMENT (TRAINING)

---

Algorithm 2: Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

```
for  $e = 1$  to  $nb\_epochs$  do
  for  $k = 1$  to  $K$  do
    if  $y_k \cdot \sigma(\mathbf{w}^T \mathbf{x}_k) < 0$  then
       $\mathbf{w} := \mathbf{w} + y_k \cdot \mathbf{x}_k$ 
    end
  end
end
return predictions
```

---

- On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $\mathbf{w} := \mathbf{w} + \gamma \cdot y_k \cdot \mathbf{x}_k$

# ENTRAÎNEMENT (TRAINING)

---

Algorithm 2: Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  **to**  $nb\_epochs$  **do**

**for**  $k = 1$  **to**  $K$  **do**

**if**  $y_k \cdot \sigma(\mathbf{w}^T \mathbf{x}_k) < 0$  **then**

$\mathbf{w} := \mathbf{w} + y_k \cdot \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---

- ▶ On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $\mathbf{w} := \mathbf{w} + \gamma \cdot y_k \cdot \mathbf{x}_k$

# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 2:** Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  **to**  $nb\_epochs$  **do**

**for**  $k = 1$  **to**  $K$  **do**

**if**  $y_k \cdot \sigma(\mathbf{w}^T \mathbf{x}_k) < 0$  **then**

$\mathbf{w} := \mathbf{w} + y_k \cdot \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---

- ▶ On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $\mathbf{w} := \mathbf{w} + \gamma \cdot y_k \cdot \mathbf{x}_k$

# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 2:** Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  **to**  $nb\_epochs$  **do**

**for**  $k = 1$  **to**  $K$  **do**

**if**  $y_k \cdot \sigma(\mathbf{w}^T \mathbf{x}_k) < 0$  **then**

$\mathbf{w} := \mathbf{w} + y_k \cdot \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---

- ▶ On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $\mathbf{w} := \mathbf{w} + \gamma \cdot y_k \cdot \mathbf{x}_k$

# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 2:** Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  **to**  $nb\_epochs$  **do**

**for**  $k = 1$  **to**  $K$  **do**

**if**  $y_k \cdot \sigma(\mathbf{w}^T \mathbf{x}_k) < 0$  **then**

$\mathbf{w} := \mathbf{w} + y_k \cdot \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---

- On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $\mathbf{w} := \mathbf{w} + \gamma \cdot y_k \cdot \mathbf{x}_k$

# ENTRAÎNEMENT (TRAINING)

---

**Algorithm 2:** Training algorithm of the perceptron (rewriting)

---

**Data:** dataset =  $\{(\mathbf{x}_i, y_i) : i = 1, \dots, K\}$

$\mathbf{w} := (0, \dots, 0, 0) = \mathbf{0}$

**for**  $e = 1$  **to**  $nb\_epochs$  **do**

**for**  $k = 1$  **to**  $K$  **do**

**if**  $y_k \cdot \sigma(\mathbf{w}^T \mathbf{x}_k) < 0$  **then**

$\mathbf{w} := \mathbf{w} + y_k \cdot \mathbf{x}_k$

**end**

**end**

**end**

**return** predictions

---


- ▶ On peut utiliser un *learning rate*  $\gamma > 0$ , ce qui modifie la règle de mise à jour en  $\mathbf{w} := \mathbf{w} + \gamma \cdot y_k \cdot \mathbf{x}_k$




# TRAINING ALGORITHM

```
def train_perceptron(x, y, nb_epochs_max):  
  
    w = torch.zeros(x.shape[1])           # initial weights (size M)  
  
    for e in range(nb_epochs_max):         # iterate over epochs  
        nb_changes = 0  
  
        for i in range(x.shape[0]):        # iterate over train set  
            if w.dot(x[i]) * y[i] <= 0:    # x_i misclassified  
                w = w + (y[i] * x[i, :])   # update weights  
                nb_changes = nb_changes + 1  
  
        if nb_changes == 0:  
            break  
  
    return w
```


## ILLUSTRATION GÉOMÉTRIQUE




## ILLUSTRATION GÉOMÉTRIQUE




## ILLUSTRATION GÉOMÉTRIQUE




## ILLUSTRATION GÉOMÉTRIQUE




## ILLUSTRATION GÉOMÉTRIQUE



## ILLUSTRATION GÉOMÉTRIQUE




## ILLUSTRATION GÉOMÉTRIQUE







## ILLUSTRATION GÉOMÉTRIQUE




# ENTRAÎNEMENT (TRAINING)




# ENTRAÎNEMENT (TRAINING)




# ENTRAÎNEMENT (TRAINING)




# ENTRAÎNEMENT (TRAINING)




# ENTRAÎNEMENT (TRAINING)



# ENTRAÎNEMENT (TRAINING)




# ENTRAÎNEMENT (TRAINING)







# ENTRAÎNEMENT (TRAINING)



# ENTRAÎNEMENT (TRAINING)



# ENTRAÎNEMENT (TRAINING)



# CONVERGENCE

- ▶ Si les points s'inscrivent dans une sphère et satisfont une certaine condition de séparabilité, alors l'algorithme converge.

## THEOREM


Soit un train set  $\mathcal{S} = \{(\mathbf{x}_k, y_k) \in \mathbb{R}^M \times \{-1, +1\} : k = 1, \dots, K\}$ .  
Supposons que:

- ▶ Il existe  $R > 0$  tel que  $\|\mathbf{x}_k\| \leq R$ , pour tous  $k = 1, \dots, K$ ;
- ▶ Il existe  $\hat{\mathbf{w}} \in \mathbb{R}^{M+1}$  et  $\gamma > 0$  tels que  $\|\hat{\mathbf{w}}\| = 1$  et

$$y_k \cdot (\mathbf{x}_k^T \hat{\mathbf{w}}) \geq \gamma, \text{ pour tous } k = 1, \dots, K.$$

Alors l'algorithme converge en au plus  $R^2/\gamma^2$  updates.

## CONVERGENCE



## BIBLIOGRAPHIE



Fleuret, F. (2022).  
Deep Learning Course.



Rosenblatt, F. (1957).  
The perceptron: A perceiving and recognizing automaton.  
Technical Report 85-460-1, Cornell Aeronautical Laboratory, Ithaca, New York.



Rosenblatt, F. (1958).  
The perceptron: A probabilistic model for information storage and organization in  
the brain.  
*Psychological Review*, 65(6):386–408.