

# PERCEPTRON MULTICOUCHES (MULTILAYER PERCEPTRON)

Jérémie Cabessa


Laboratoire DAVID, UVSQ

# PERCEPTRON

Le **perceptron** est un neurone qui agit comme un classifieur binaire.  
Sa dynamique est donnée par:

$$a = \sigma(w^T x + b)$$

- ▶  $x = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les inputs;
- ▶  $w = (w_1, \dots, w_M) \in \mathbb{R}^M$  sont les poids synaptiques;
- ▶  $b \in \mathbb{R}$  est le biais;
- ▶  $\sigma : \mathbb{R} \rightarrow \mathbb{R}$  est une fonction d'activation sigmoïdale.
- ▶  $a$  est l'activation du neurone.




# PERCEPTRON

Le **perceptron** est un neurone qui agit comme un classifieur binaire.  
Sa dynamique est donnée par:

$$a = \sigma(\mathbf{w}^T \mathbf{x} + b)$$

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les inputs;
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  sont les poids synaptiques;
- ▶  $b \in \mathbb{R}$  est le biais;
- ▶  $\sigma : \mathbb{R} \rightarrow \mathbb{R}$  est une fonction d'activation sigmoïdale.
- ▶  $a$  est l'activation du neurone.




# PERCEPTRON

Le **perceptron** est un neurone qui agit comme un classifieur binaire.  
Sa dynamique est donnée par:

$$a = \sigma(w^T x + b)$$

- ▶  $x = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les inputs;
- ▶  $w = (w_1, \dots, w_M) \in \mathbb{R}^M$  sont les poids synaptiques;
- ▶  $b \in \mathbb{R}$  est le biais;
- ▶  $\sigma : \mathbb{R} \rightarrow \mathbb{R}$  est une fonction d'activation sigmoïdale.
- ▶  $a$  est l'activation du neurone.




# PERCEPTRON

Le **perceptron** est un neurone qui agit comme un classifieur binaire. Sa dynamique est donnée par:

$$a = \sigma \left( \mathbf{w}^T \mathbf{x} + b \right)$$

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les inputs;
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  sont les poids synaptiques;
- ▶  $b \in \mathbb{R}$  est le biais;
- ▶  $\sigma : \mathbb{R} \rightarrow \mathbb{R}$  est une fonction d'activation sigmoïdale.
- ▶  $a$  est l'activation du neurone.




# PERCEPTRON

Le **perceptron** est un neurone qui agit comme un classifieur binaire.  
Sa dynamique est donnée par:


$$a = \sigma(\mathbf{w}^T \mathbf{x} + b)$$

- ▶  $\mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$  sont les inputs;
- ▶  $\mathbf{w} = (w_1, \dots, w_M) \in \mathbb{R}^M$  sont les poids synaptiques;
- ▶  $b \in \mathbb{R}$  est le biais;
- ▶  $\sigma : \mathbb{R} \rightarrow \mathbb{R}$  est une fonction d'activation sigmoïdale.
- ▶  $a$  est l'activation du neurone.




## PERCEPTRON: 1 NEURONE

$$a = \sigma \left( \mathbf{w}^T \mathbf{x} + b \right) \text{ où } \mathbf{w} = (w_1, \dots, w_M)$$



## PERCEPTRON: 1 COUCHE

$$a_i = \sigma_i(\mathbf{w}_i^T \mathbf{x} + b_i) \text{ où } \mathbf{w}_i = (w_{i1}, \dots, w_{iM}), i = 1, 2, 3.$$






## PERCEPTRON: 1 COUCHE


$$\mathbf{a} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}) \quad \text{où} \quad \mathbf{W} = \begin{pmatrix} \cdots \mathbf{w}_1^T \cdots \\ \cdots \mathbf{w}_2^T \cdots \\ \cdots \mathbf{w}_3^T \cdots \end{pmatrix} = \begin{pmatrix} w_{11} & \cdots & w_{1M} \\ w_{21} & \cdots & w_{2M} \\ w_{31} & \cdots & w_{3M} \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \end{pmatrix}$$

et  $\sigma = (\sigma_1, \sigma_2, \sigma_3)$  appliquée composante par composante.



## PERCEPTRON: 1 COUCHE


$$\begin{pmatrix} a_1 \\ a_2 \\ a_3 \end{pmatrix} = \sigma \left[ \begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} & w_{15} \\ w_{21} & w_{22} & w_{23} & w_{24} & w_{25} \\ w_{31} & w_{32} & w_{33} & w_{34} & w_{35} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} + \begin{pmatrix} b_1 \\ b_2 \\ b_3 \end{pmatrix} \right]$$



►  $w_{ij}$ : poids de l'input  $j$  vers neurone  $i$  (et non de  $i$  vers  $j$ ).

## PERCEPTRON: 1 COUCHE

$$\begin{pmatrix} a_1 \\ a_2 \\ a_3 \end{pmatrix} = \sigma \left[ \begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} & w_{15} \\ w_{21} & w_{22} & w_{23} & w_{24} & w_{25} \\ w_{31} & w_{32} & w_{33} & w_{34} & w_{35} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} + \begin{pmatrix} b_1 \\ b_2 \\ b_3 \end{pmatrix} \right]$$




- $w_{ij}$ : poids de l'input  $j$  vers neurone  $i$  (et non de  $i$  vers  $j$ ).


## PERCEPTRON: 2 COUCHES

$$a^{[1]} = \sigma \left( W^{[1]}x + b^{[1]} \right) := \sigma \left( z^{[1]} \right)$$

$$a^{[2]} = \sigma \left( W^{[2]}a^{[1]} + b^{[2]} \right) := \sigma \left( z^{[2]} \right)$$

où  $W^{[i]} = \begin{pmatrix} \dots w_1^{[i]T} \dots \\ \dots \dots \dots \\ \dots w_{l_i}^{[i]T} \dots \end{pmatrix} = \begin{pmatrix} w_{11}^{[i]} & \dots & w_{1l_{i-1}}^{[i]} \\ \dots & \dots & \dots \\ w_{l_i 1}^{[i]} & \dots & w_{l_i l_{i-1}}^{[i]} \end{pmatrix}$  et  $b = \begin{pmatrix} b_1^{[i]} \\ \vdots \\ b_{l_i}^{[i]} \end{pmatrix}$   $i = 1, 2$




$$\begin{cases} \mathbf{a}^{[0]} &= \mathbf{x} \\ \mathbf{z}^{[l]} &= \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}, \\ \mathbf{a}^{[l]} &= \sigma(\mathbf{z}^{[l]}) \end{cases}, \quad l = 1, \dots, L$$


# MULTI LAYER PERCEPTRON (MLP)

$$\begin{cases} \mathbf{a}^{[0]} = \mathbf{x} \\ \mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}, \\ \mathbf{a}^{[l]} = \sigma(\mathbf{z}^{[l]}) \end{cases} \quad l = 1, \dots, L$$


- ▶  $\mathbf{x}$  est l'input et  $\mathbf{a}^{[L]}$  est l'output
- ▶  $\mathbf{W}^{[l]} \in \mathbb{R}^{\lambda_l \times \lambda_{l-1}}$  et  $\mathbf{b}^{[l]} \in \mathbb{R}^{\lambda_l}$ , où  $\lambda_l$  taille de la couche  $l$
- ▶  $w_{ij}^{[l]}$ : poids du neurone  $j$  (couche  $l-1$ ) vers neurone  $i$  (couche  $l$ )



## MULTI LAYER PERCEPTRON (MLP)

$$\begin{cases} \mathbf{a}^{[0]} = \mathbf{x} \\ \mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}, \\ \mathbf{a}^{[l]} = \sigma(\mathbf{z}^{[l]}) \end{cases} \quad l = 1, \dots, L$$


- ▶  $\mathbf{x}$  est l'input et  $\mathbf{a}^{[L]}$  est l'output
- ▶  $\mathbf{W}^{[l]} \in \mathbb{R}^{\lambda_l \times \mathbb{R}^{\lambda_{l-1}}}$  et  $\mathbf{b}^{[l]} \in \mathbb{R}^{\lambda_l}$ , où  $\lambda_l$  taille de la couche  $l$
- ▶  $w_{ij}^{[l]}$ : poids du neurone  $j$  (couche  $l-1$ ) vers neurone  $i$  (couche  $l$ )



## MULTI LAYER PERCEPTRON (MLP)


$$\begin{cases} \mathbf{a}^{[0]} = \mathbf{x} \\ \mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}, \\ \mathbf{a}^{[l]} = \sigma(\mathbf{z}^{[l]}) \end{cases} \quad l = 1, \dots, L$$

- ▶  $\mathbf{x}$  est l'input et  $\mathbf{a}^{[L]}$  est l'output
- ▶  $\mathbf{W}^{[l]} \in \mathbb{R}^{\lambda_l \times \mathbb{R}^{\lambda_{l-1}}}$  et  $\mathbf{b}^{[l]} \in \mathbb{R}^{\lambda_l}$ , où  $\lambda_l$  taille de la couche  $l$
- ▶  $w_{ij}^{[l]}$ : poids du neurone  $j$  (couche  $l-1$ ) vers neurone  $i$  (couche  $l$ )







## MLP: REPRÉSENTATION GRAPHIQUE





# SÉPARABILITÉ NON-LINÉAIRE

- **Rappel:** dans le cas de perceptrons avec fonction d'activation heaviside, chaque neurone représente un hyperplan dans l'espace de ses inputs.
- Remarque importante: un réseau de perceptron à 2 couches peut alors implémenter une frontière de décision non-linéaire!




# SÉPARABILITÉ NON-LINÉAIRE

- **Rappel:** dans le cas de perceptrons avec fonction d'activation heaviside, chaque neurone représente un hyperplan dans l'espace de ses inputs.
- **Remarque importante:** un réseau de perceptron à 2 couches peut alors implémenter une frontière de décision non-linéaire!



## MLP: FORWARD PASS

$$\begin{cases} \mathbf{a}^{[0]} = \mathbf{x} \\ \mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}, \\ \mathbf{a}^{[l]} = \sigma(\mathbf{z}^{[l]}) \end{cases} \quad l = 1, \dots, L$$



# MLP: FORWARD PASS

---

## Algorithm 1: MLP: forward pass

---

**Data:** dataset =  $\{(\mathbf{x}_i, \mathbf{y}_i) : i = 1, \dots, N\}$   
**Inputs:** MLP =  $\{(\mathbf{W}^{[l]}, \mathbf{b}^{[l]}) : l = 1, \dots, L\}$

```
predictions = []
for i = 1 to N do
     $\mathbf{a}^{[0]} = \mathbf{x}_i$ 
    for l = 1 to L do
         $\mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}$ 
         $\mathbf{a}^{[l]} = \sigma(\mathbf{z}^{[l]})$ 
    end
    predictions.append( $\mathbf{a}^{[L]}$ )
end
return predictions
```

---

# MLP: FORWARD PASS

---

## Algorithm 1: MLP: forward pass

---

**Data:** dataset =  $\{(\mathbf{x}_i, \mathbf{y}_i) : i = 1, \dots, N\}$

**Inputs:** MLP =  $\{(\mathbf{W}^{[l]}, \mathbf{b}^{[l]}) : l = 1, \dots, L\}$

predictions = []

for  $i = 1$  to  $N$  do

$\mathbf{a}^{[0]} = \mathbf{x}_i$

    for  $l = 1$  to  $L$  do

$\mathbf{z}^{[l]} = \mathbf{W}^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}$

$\mathbf{a}^{[l]} = \sigma(\mathbf{z}^{[l]})$

    end

    predictions.append( $\mathbf{a}^{[L]}$ )

end

return predictions

---

// forward pass

# MLP: FORWARD PASS

---

## Algorithm 1: MLP: forward pass

---

**Data:** dataset =  $\{(x_i, y_i) : i = 1, \dots, N\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $N$  **do**

$a^{[0]} = x_i$

**for**  $l = 1$  **to**  $L$  **do**

$z^{[l]} = W^{[l]}a^{[l-1]} + b^{[l]}$

$a^{[l]} = \sigma(z^{[l]})$

**end**

    predictions.append( $a^{[L]}$ )

**end**

**return** predictions

---

// forward pass

# MLP: FORWARD PASS

---

## Algorithm 1: MLP: forward pass

---

**Data:** dataset =  $\{(x_i, y_i) : i = 1, \dots, N\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $N$  **do**

$a^{[0]} = x_i$

**for**  $l = 1$  **to**  $L$  **do**

$z^{[l]} = W^{[l]}a^{[l-1]} + b^{[l]}$

$a^{[l]} = \sigma(z^{[l]})$

**end**

    predictions.append( $a^{[L]}$ )

**end**

**return** predictions

---

// forward pass



# MLP: FORWARD PASS

---

## Algorithm 1: MLP: forward pass

---

**Data:** dataset =  $\{(x_i, y_i) : i = 1, \dots, N\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $N$  **do**

$a^{[0]} = x_i$

**for**  $l = 1$  **to**  $L$  **do**

$z^{[l]} = W^{[l]}a^{[l-1]} + b^{[l]}$

$a^{[l]} = \sigma(z^{[l]})$

**end**

    predictions.append( $a^{[L]}$ )

**end**

return predictions

---

// forward pass

# MLP: FORWARD PASS

---

**Algorithm 1:** MLP: forward pass

---

**Data:** dataset =  $\{(x_i, y_i) : i = 1, \dots, N\}$ **Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$ 

predictions = []

**for**  $i = 1$  **to**  $N$  **do**     $a^{[0]} = x_i$     **for**  $l = 1$  **to**  $L$  **do**         $z^{[l]} = W^{[l]}a^{[l-1]} + b^{[l]}$          $a^{[l]} = \sigma(z^{[l]})$     **end**    predictions.append( $a^{[L]}$ )**end****return** predictions

---

// forward pass

# MLP: FORWARD PASS (BATCHED)

- Soit le dataset  $S = \{(x_i, y_i) : i = 1, \dots, N\}$
- On peut *paralléliser* la forward pass en passant les data "batch par batch" (batches de taille  $B = 32, 64, \dots$ ).
- Le  $i$ -ème batch  $B_i = (X_i, Y_i)$  est composé de  $B$  inputs et outputs  $x_k$  et  $y_k$  alignés en deux matrices:

$$X_i = \begin{pmatrix} \vdots & \vdots & \cdots & \vdots \\ x_1 & x_2 & \cdots & x_B \\ \vdots & \vdots & \cdots & \vdots \end{pmatrix} \text{ et } Y_i = \begin{pmatrix} \vdots & \vdots & \cdots & \vdots \\ y_1 & y_2 & \cdots & y_B \\ \vdots & \vdots & \cdots & \vdots \end{pmatrix}$$

# MLP: FORWARD PASS (BATCHED)

- ▶ Soit le dataset  $S = \{(x_i, y_i) : i = 1, \dots, N\}$
- ▶ On peut *paralléliser* la forward pass en passant les data “batch par batch” (batches de taille  $B = 32, 64, \dots$ ).
- ▶ Le  $i$ -ème batch  $B_i = (X_i, Y_i)$  est composé de  $B$  inputs et outputs  $x_k$  et  $y_k$  alignés en deux matrices:

$$X_i = \begin{pmatrix} \vdots & \vdots & \cdots & \vdots \\ x_1 & x_2 & \cdots & x_B \\ \vdots & \vdots & \cdots & \vdots \end{pmatrix} \text{ et } Y_i = \begin{pmatrix} \vdots & \vdots & \cdots & \vdots \\ y_1 & y_2 & \cdots & y_B \\ \vdots & \vdots & \cdots & \vdots \end{pmatrix}$$

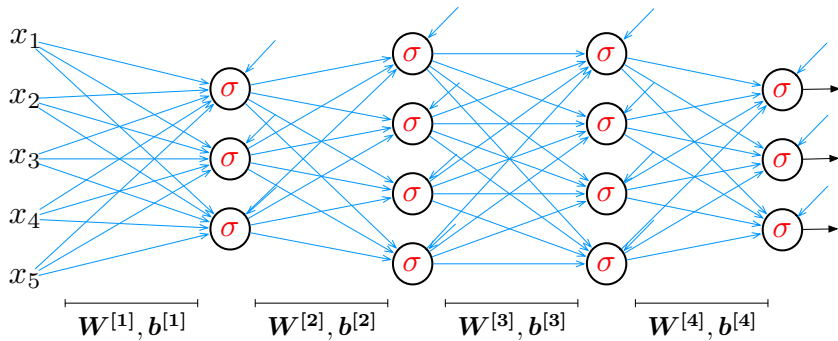
# MLP: FORWARD PASS (BATCHED)

- ▶ Soit le dataset  $S = \{(x_i, y_i) : i = 1, \dots, N\}$
- ▶ On peut *paralléliser* la forward pass en passant les data "batch par batch" (batches de taille  $B = 32, 64, \dots$ ).
- ▶ Le  $i$ -ème batch  $B_i = (X_i, Y_i)$  est composé de  $B$  inputs et outputs  $x_k$  et  $y_k$  alignés en deux matrices:

$$X_i = \begin{pmatrix} \vdots & \vdots & \cdots & \vdots \\ x_1 & x_2 & \cdots & x_B \\ \vdots & \vdots & \cdots & \vdots \end{pmatrix} \text{ et } Y_i = \begin{pmatrix} \vdots & \vdots & \cdots & \vdots \\ y_1 & y_2 & \cdots & y_B \\ \vdots & \vdots & \cdots & \vdots \end{pmatrix}$$

## MLP: FORWARD PASS (BATCHED)

$$\begin{cases} \mathbf{A}^{[0]} = \mathbf{X}_i \\ \mathbf{Z}^{[l]} = \mathbf{W}^{[l]} \mathbf{A}^{[l-1]} \oplus \mathbf{b}^{[l]}, \\ \mathbf{A}^{[l]} = \sigma(\mathbf{Z}^{[l]}) \end{cases} \quad l = 1, \dots, L$$



# MLP: FORWARD PASS (BATCHED)

---

## Algorithm 2: MLP: forward pass (batched)

---

**Data:** dataloader =  $\{B_i = (X_i, Y_i) : i = 1, \dots, B\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

```
predictions = []
for i = 1 to B do                                // loop over batches
    A[0] = Xi
    for l = 1 to L do                             // forward pass
        Z[l] = W[l]A[l-1] + b[l]
        A[l] = σ(Z[l])
    end
    predictions.append(A[L])
end
return concat(predictions)
```

---

# MLP: FORWARD PASS (BATCHED)

---

## Algorithm 2: MLP: forward pass (batched)

---

**Data:** dataloader =  $\{B_i = (X_i, Y_i) : i = 1, \dots, B\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

```
for i = 1 to B do                                // loop over batches
     $A^{[0]} = X_i$ 
    for l = 1 to L do                             // forward pass
         $Z^{[l]} = W^{[l]} A^{[l-1]} + b^{[l]}$ 
         $A^{[l]} = \sigma(Z^{[l]})$ 
    end
    predictions.append( $A^{[L]}$ )
end
return concat(predictions)
```

---



# MLP: FORWARD PASS (BATCHED)

---

## Algorithm 2: MLP: forward pass (batched)

---

**Data:** dataloader =  $\{B_i = (X_i, Y_i) : i = 1, \dots, B\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $B$  **do**

// loop over batches

$A^{[0]} = X_i$

**for**  $l = 1$  **to**  $L$  **do**

// forward pass

$Z^{[l]} = W^{[l]}A^{[l-1]} + b^{[l]}$

$A^{[l]} = \sigma(Z^{[l]})$

**end**

    predictions.append( $A^{[L]}$ )

**end**

**return** concat(predictions)

---

# MLP: FORWARD PASS (BATCHED)

---

**Algorithm 2:** MLP: forward pass (batched)

---

**Data:** dataloader =  $\{B_i = (X_i, Y_i) : i = 1, \dots, B\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $B$  **do**

// loop over batches

$A^{[0]} = X_i$

**for**  $l = 1$  **to**  $L$  **do**

// forward pass

$Z^{[l]} = W^{[l]} A^{[l-1]} + b^{[l]}$

$A^{[l]} = \sigma(Z^{[l]})$

**end**

    predictions.append( $A^{[L]}$ )

**end**

**return** concat(predictions)

---

# MLP: FORWARD PASS (BATCHED)

---

## Algorithm 2: MLP: forward pass (batched)

---

**Data:** dataloader =  $\{B_i = (X_i, Y_i) : i = 1, \dots, B\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $B$  **do**

// loop over batches

$A^{[0]} = X_i$

**for**  $l = 1$  **to**  $L$  **do**

// forward pass

$Z^{[l]} = W^{[l]} A^{[l-1]} + b^{[l]}$

$A^{[l]} = \sigma(Z^{[l]})$

**end**

    predictions.append( $A^{[L]}$ )

**end**

return concat(predictions)

---

# MLP: FORWARD PASS (BATCHED)

---

**Algorithm 2:** MLP: forward pass (batched)

---

**Data:** dataloader =  $\{B_i = (X_i, Y_i) : i = 1, \dots, B\}$

**Inputs:** MLP =  $\{(W^{[l]}, b^{[l]}) : l = 1, \dots, L\}$

predictions = []

**for**  $i = 1$  **to**  $B$  **do**

// loop over batches

$A^{[0]} = X_i$

**for**  $l = 1$  **to**  $L$  **do**

// forward pass

$Z^{[l]} = W^{[l]} A^{[l-1]} + b^{[l]}$

$A^{[l]} = \sigma(Z^{[l]})$

**end**


    predictions.append( $A^{[L]}$ )

**end**

**return** concat(predictions)

---

## MLP: REPRÉSENTATION GRAPHIQUE (BATCHED)



carrés = variables

ronds = opérations

## BIBLIOGRAPHIE



Fleuret, F. (2022).  
Deep Learning Course.