# Transformers

Jérémie Cabessa

Laboratoire DAVID, UVSQ

# Architecture encodeur-décodeur

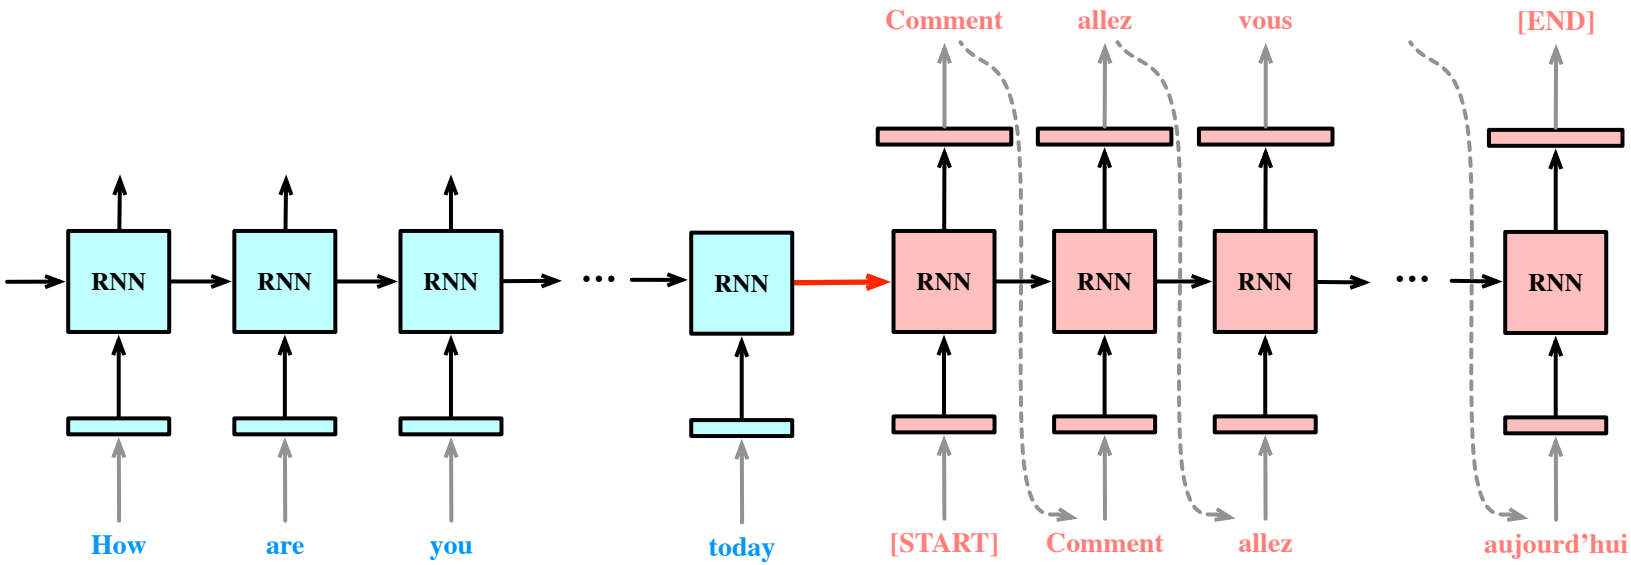


- Le dernier vecteur de l'encodeur est le *context vector* (rouge). C'est un *embedding* qui encode toutes les inputs et permet le décodage.

# Architecture encodeur-décodeur

- Les réseaux récurrents (RNNs) souffrent de la *disparition du gradient (vanishing gradient)*.
- Les RNNs ne permettent pas la *parallélisation*: la forward pass doit être calculée de manière séquentielle, car les états sucessifs du réseaux sont donnés par l'historique des inputs.
- Les RNNs ont peine à capturer les dépendances de long termes entre les inputs (long-term dependencies).

$\Rightarrow$ **Solution:** architecture *feedforward* (no vanishing/exploding gradients, parallelizable) couplée à un mécanisme d'*attention* (short and long term dependencies).

# Architecture encodeur-décodeur

- Les réseaux récurrents (RNNs) souffrent de la *disparition du gradient (vanishing gradient)*.
- Les RNNs ne permettent pas la *parallélisation*: la forward pass doit être calculée de manière séquentielle, car les états sucessifs du réseaux sont donnés par l'historique des inputs.
- Les RNNs ont peine à capturer les dépendances de long termes entre les inputs (long-term dependencies).

$\Rightarrow$ **Solution:** architecture *feedforward* (no vanishing/exploding gradients, parallelizable) couplée à un mécanisme d'*attention* (short and long term dependencies).

# Architecture encodeur-décodeur

- Les réseaux récurrents (RNNs) souffrent de la *disparition du gradient (vanishing gradient)*.
- Les RNNs ne permettent pas la *parallélisation*: la forward pass doit être calculée de manière séquentielle, car les états sucessifs du réseaux sont donnés par l'historique des inputs.
- Les RNNs ont peine à capturer les dépendances de long termes entre les inputs (long-term dependencies).

$\Rightarrow$ **Solution:** architecture *feedforward* (no vanishing/exploding gradients, parallelizable) couplée à un mécanisme d'*attention* (short and long term dependencies).

# Architecture encodeur-décodeur

- Les réseaux récurrents (RNNs) souffrent de la *disparition du gradient (vanishing gradient)*.
- Les RNNs ne permettent pas la *parallélisation*: la forward pass doit être calculée de manière séquentielle, car les états sucessifs du réseaux sont donnés par l'historique des inputs.
- Les RNNs ont peine à capturer les dépendances de long termes entre les inputs (long-term dependencies).

$\Rightarrow$ **Solution:** architecture *feedforward* (no vanishing/exploding gradients, parallelizable) couplée à un mécanisme d'*attention* (short and long term dependencies).

# Transformer

## Transformer

- Architecture **encodeur-décodeur**.
- Réseau de neurones **feedforward** (no vanishing/exploding gradients, parallelizable)
- Mécanismes de **self-attention** et d'**attention** dans l'encodeur et le décodeur (short and long term dependencies).

# Transformer

## Transformer

- Architecture **encodeur-décodeur**.
- Réseau de neurones **feedforward** (no vanishing/exploding gradients, parallelizable)
- Mécanismes de **self-attention** et d'**attention** dans l'encodeur et le décodeur (short and long term dependencies).

# Transformer

**Transformer**

- Architecture **encodeur-décodeur**.
- Réseau de neurones **feedforward** (no vanishing/exploding gradients, parallelizable)
- Mécanismes de **self-attention** et d'**attention** dans l'encodeur et le décodeur (short and long term dependencies).

# Transformer

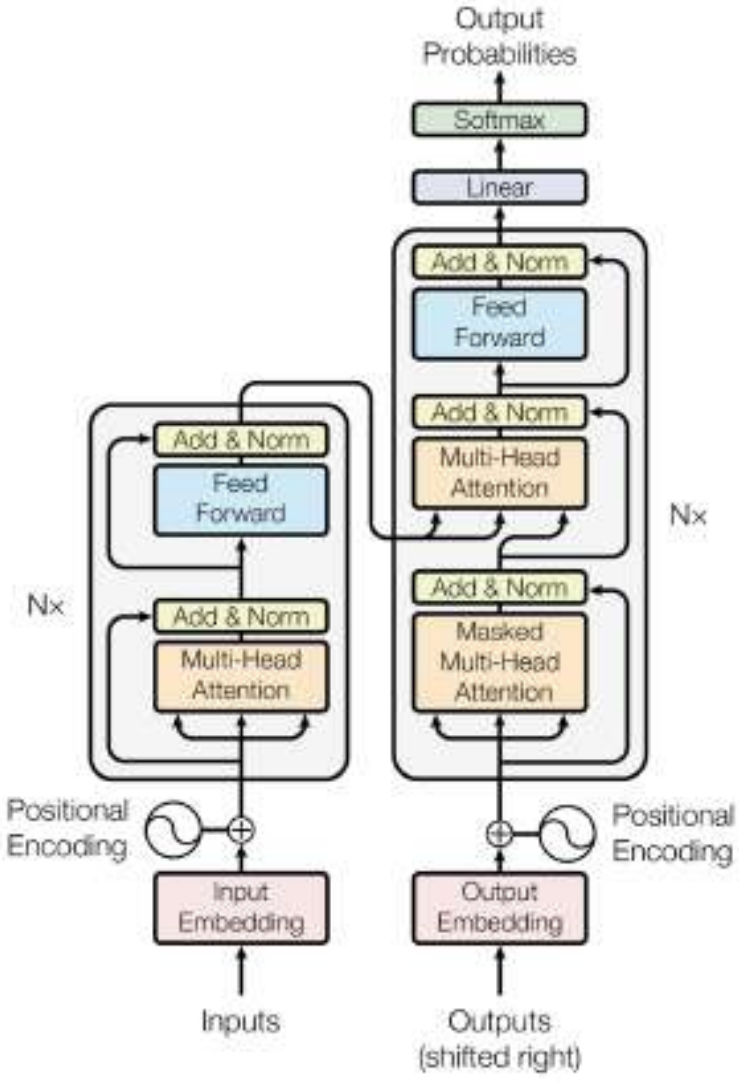


Figure taken from [Vaswani et al., 2017].

# Transformer

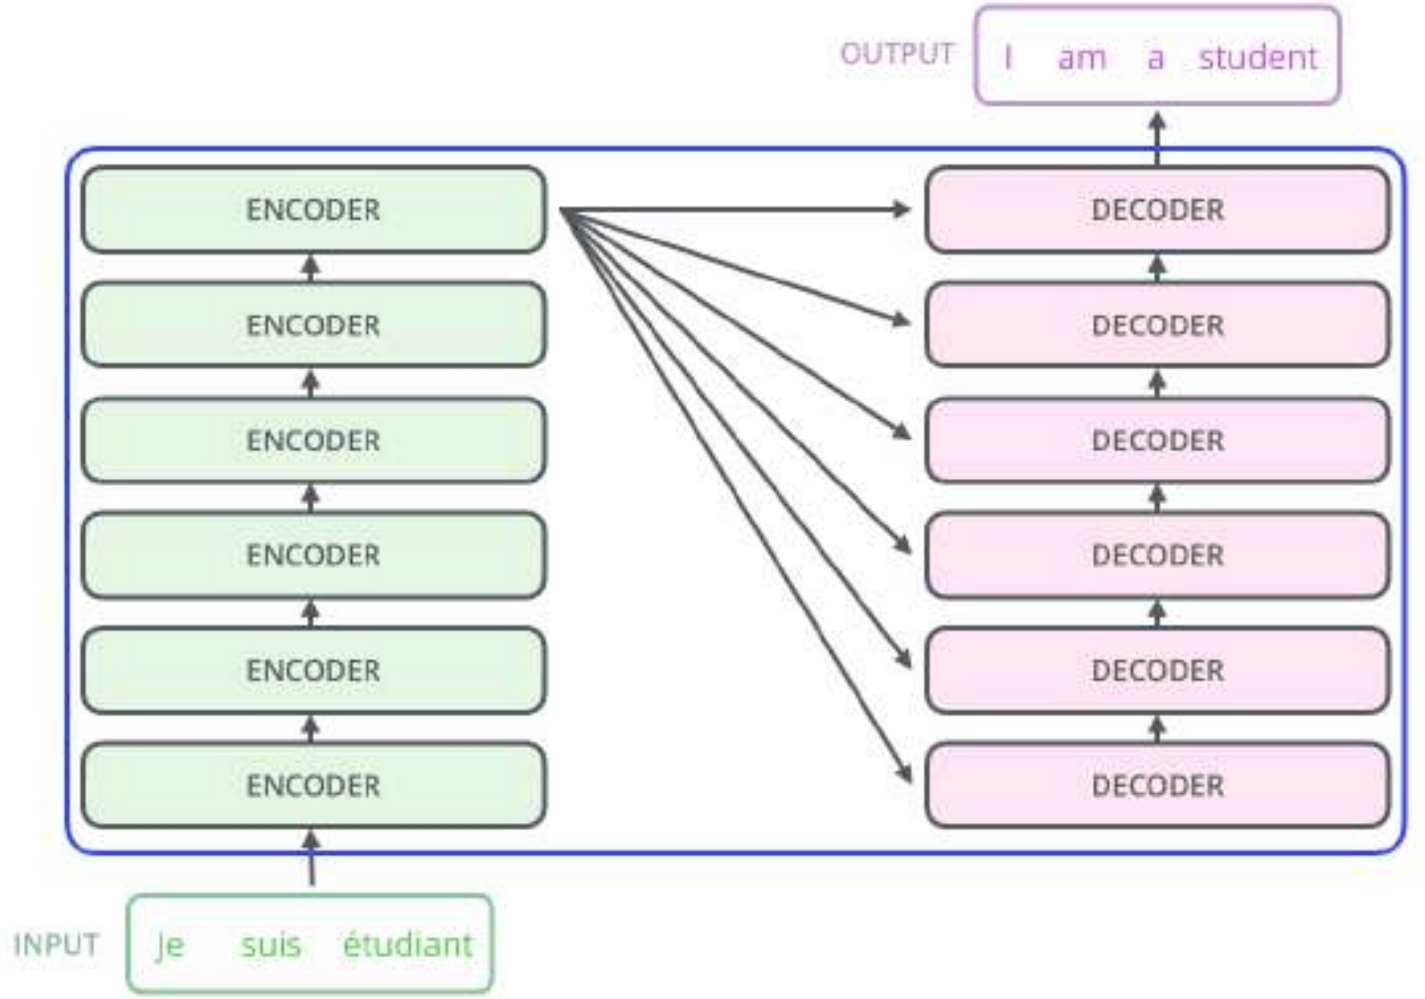


Figure taken from [Alammar, 2018].

# Transformer

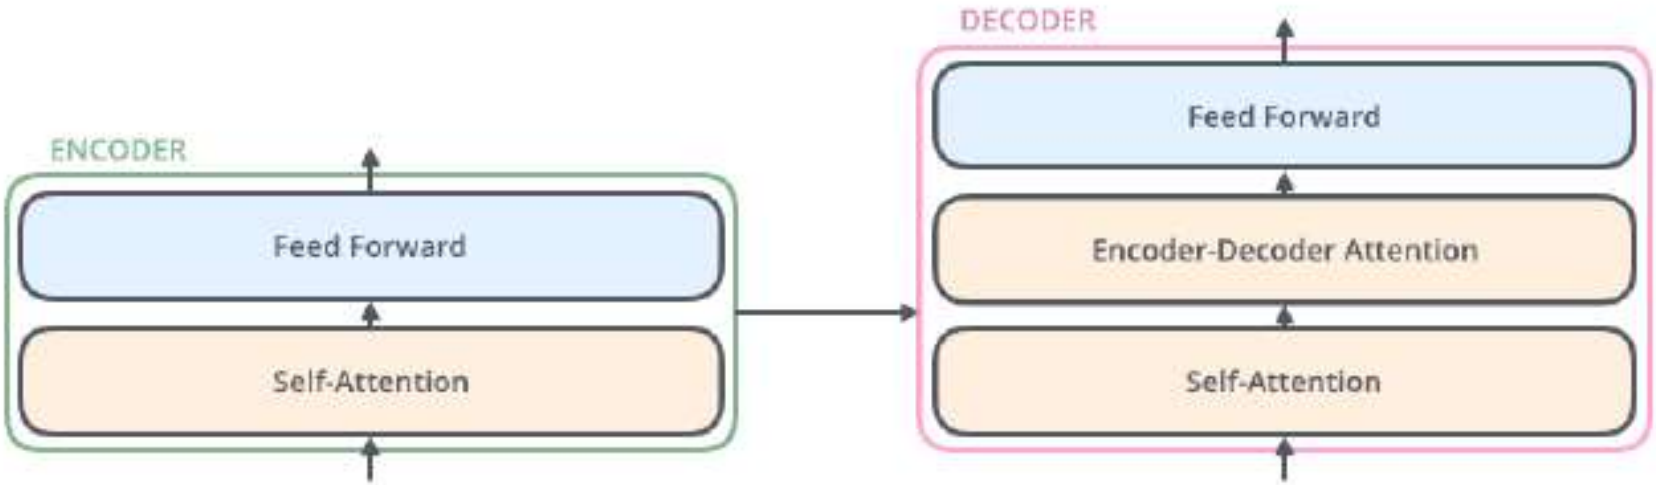


Figure taken from [Alammar, 2018].

# Transformer

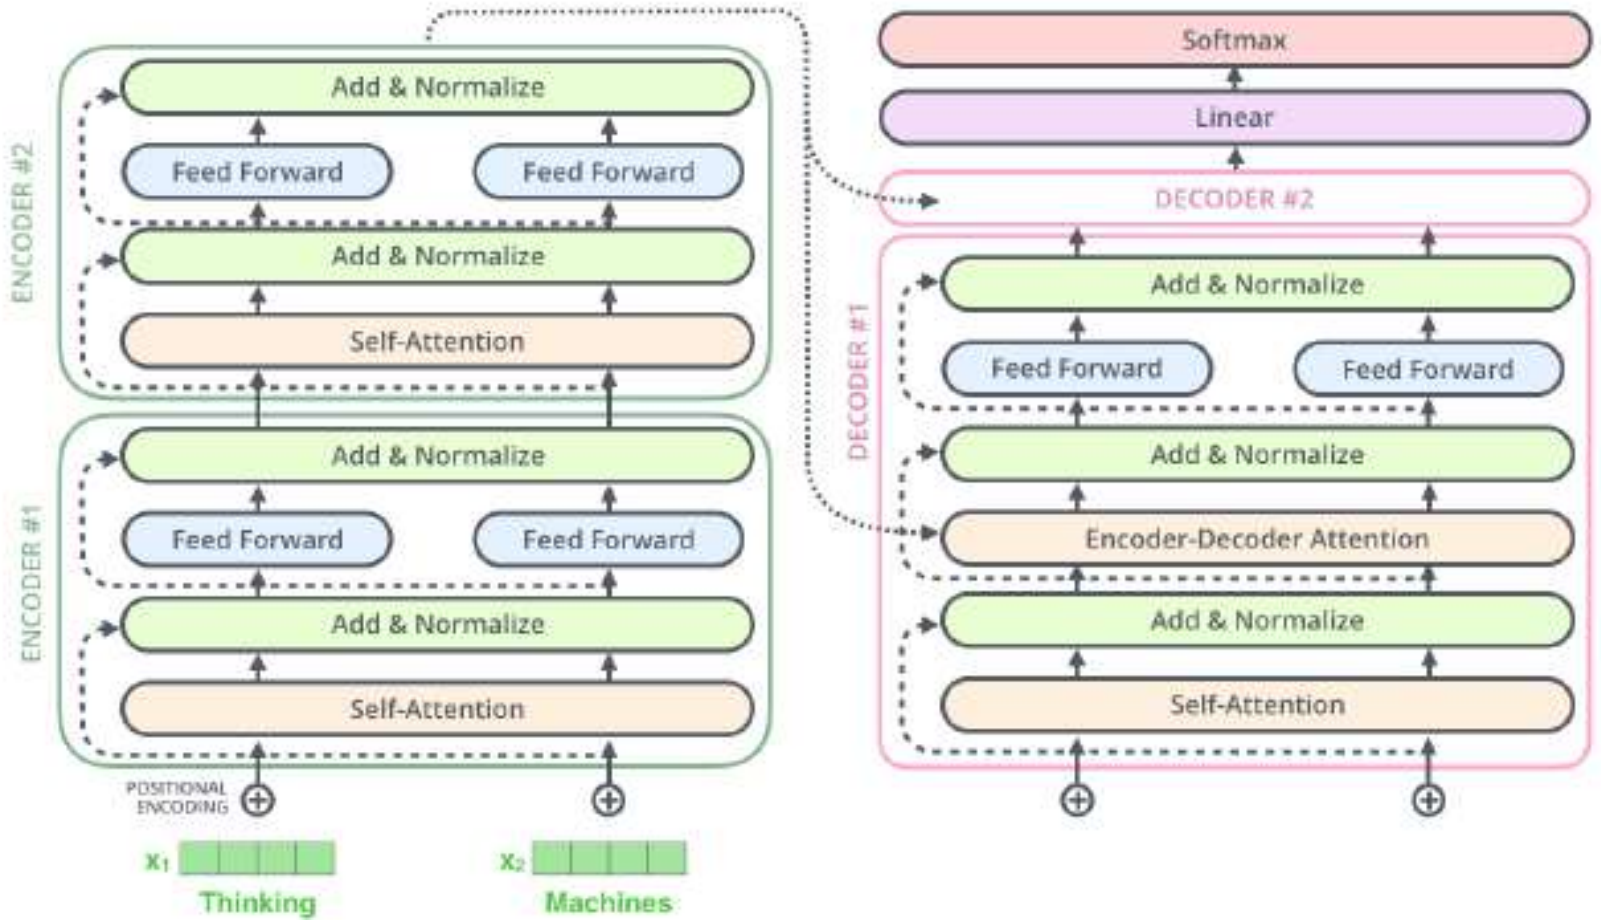


Figure taken from [Alammar, 2018].

# Tokenization et embedding

- Le text passé en input est "tokenisé", i.e., convertit en une séquence de "input tokens".
- Chaque input token est associé à un entier appelé "token id", qui est à un indice dans un vocabulaire d'environ 40K mots.
- Chaque token id est ensuite "embeddé" en un vecteur de taille 512 par le biais d'un embedding sous forme de lookup matrice de dim $30K \times 512$.
- À chaque "input embedding" est ajouté un vecteur de "positional encoding" qui capture l'information de la position de cet input dans le texte de départ.

# Tokenization et embedding

- Le text passé en input est "tokenisé", i.e., convertit en une séquence de "input tokens".
- Chaque input token est associé à un entier appelé "token id", qui est à un indice dans un vocabulaire d'environ 40K mots.
- Chaque token id est ensuite "embeddé" en un vecteur de taille 512 par le biais d'un embedding sous forme de lookup matrice de dim $30K \times 512$.
- À chaque "input embedding" est ajouté un vecteur de "positional encoding" qui capture l'information de la position de cet input dans le texte de départ.

# Tokenization et embedding

- Le text passé en input est "tokenisé", i.e., convertit en une séquence de "input tokens".
- Chaque input token est associé à un entier appelé "token id", qui est à un indice dans un vocabulaire d'environ 40K mots.
- Chaque token id est ensuite "embeddé" en un vecteur de taille 512 par le biais d'un embedding sous forme de lookup matrice de dim $30K \times 512$.
- À chaque "input embedding" est ajouté un vecteur de "positional encoding" qui capture l'information de la position de cet input dans le texte de départ.

# Tokenization et embedding

- Le text passé en input est "tokenisé", i.e., convertit en une séquence de "input tokens".
- Chaque input token est associé à un entier appelé "token id", qui est à un indice dans un vocabulaire d'environ 40K mots.
- Chaque token id est ensuite "embeddé" en un vecteur de taille 512 par le biais d'un embedding sous forme de lookup matrice de dim $30K \times 512$.
- À chaque "input embedding" est ajouté un vecteur de "positional encoding" qui capture l'information de la position de cet input dans le texte de départ.

# Tokenization et embedding

## Exemple:

```
# Original Sentence
Let's learn deep learning!

# Tokenized Sentence
["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens
["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding
["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs
[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence
Let's learn deep learning!

# Tokenized Sentence
["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens
["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding
["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs
[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple:

```
# Original Sentence

Let's learn deep learning!

# Tokenized Sentence

["Let", "'", "s", "learn", "deep", "learning", "!"]

# Adding [CLS] and [SEP] Tokens

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]"]

# Padding

["[CLS]", "Let", "'", "s", "learn", "deep", "learning", "!", "[SEP]",
"[PAD]"]

# Converting to IDs

[101, 2421, 112, 188, 3858, 1996, 3776, 106, 102, 0]
```

# Tokenization et embedding

## Exemple (suite):

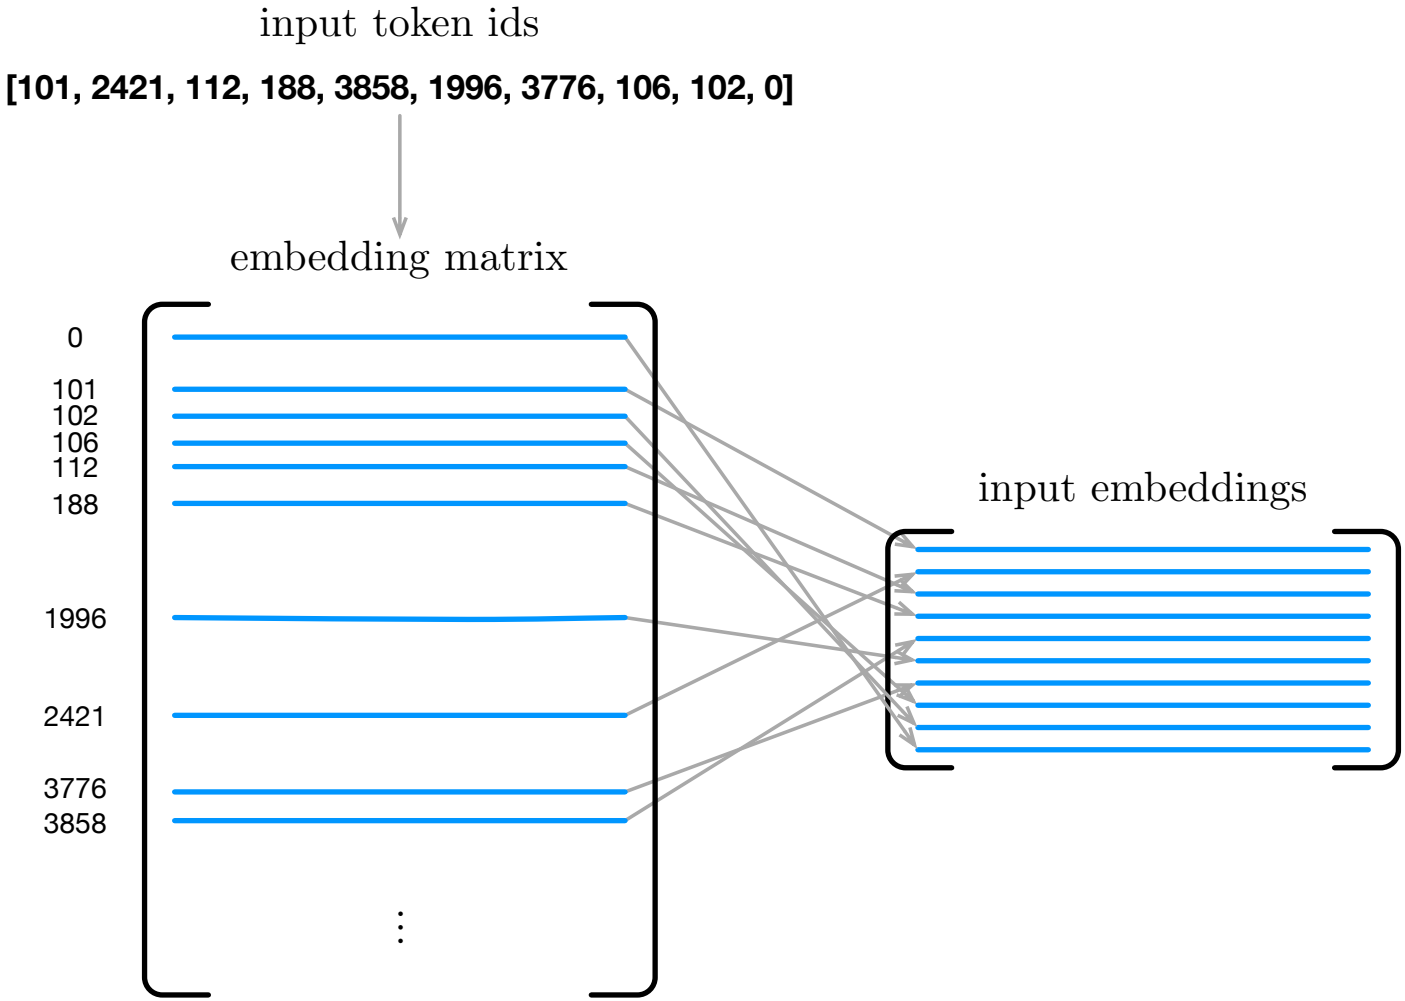

# Tokenization et embedding

**Exemple (suite):**

$$PE(pos, 2i) = \sin\left(pos/10000^{\frac{2i}{d}}\right)$$
$$PE(pos, 2i+1) = \cos\left(pos/10000^{\frac{2i}{d}}\right)$$

où $pos$ est la position du input token $(0, 1, 2, \dots)$, $i$ est la dimension de l'encoding $(0 \leq i \leq 511)$, et $d = 512$.

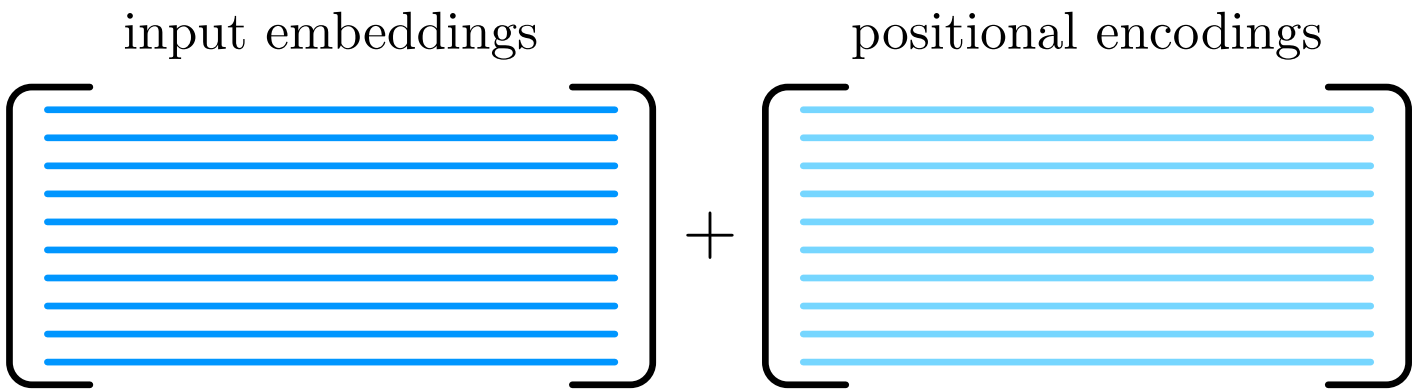

# Attention

- On distingue 2 types d'attention:
  - l'attention classique
  - la self-attention

# Attention

- On distingue 2 types d'attention:
  - **l'attention classique**
  - la self-attention

# Attention

- On distingue 2 types d'attention:
  - **l'attention classique**
  - **la self-attention**

# Attention

- **Attention (intuition générale):** Analogie avec un *système de recherche (retrieval system)* basé sur des *requêtes*, des *clés* et des *valeurs (queries, keys, and values)*.
- On a une base de données d'éléments représentés par des couples clé-valeur. Pour une requête donnée, on cherche les clés qui possèdent le plus de similarités avec celle-ci et on extrait les valeurs correspondantes.
- *A "query" matches different "keys" and retrieves the corresponding "values".*

# Attention

- **Attention (intuition générale):** Analogie avec un *système de recherche (retrieval system)* basé sur des *requêtes*, des *clés* et des *valeurs (queries, keys, and values)*.
- On a une base de données d'éléments représentés par des couples clé-valeur. Pour une requête donnée, on cherche les clés qui possèdent le plus de similarités avec celle-ci et on extrait les valeurs correspondantes.
- *A "query" matches different "keys" and retrieves the corresponding "values".*

# Attention

- **Attention (intuition générale):** Analogie avec un *système de recherche (retrieval system)* basé sur des *requêtes*, des *clés* et des *valeurs (queries, keys, and values)*.
- On a une base de données d'éléments représentés par des couples clé-valeur. Pour une requête donnée, on cherche les clés qui possèdent le plus de similarités avec celle-ci et on extrait les valeurs correspondantes.
- *A "query" matches different "keys" and retrieves the corresponding "values".*

# Scaled Dot-Product Attention

- Pour la self-attention qui se déroule dans l'encodeur, les requêtes, les clés et les valeurs proviennent de la séquence des inputs.
- Pour la self-attention qui se déroule dans décodeur, les requêtes, les clés et les valeurs proviennent de la séquence des mots décodés jusqu'à maintenant.
- Pour l'attention qui se déroule dans décodeur, les requêtes proviennent des outputs de l'encodeur, et les clés et les valeurs proviennent de la séquence des mots décodés jusqu'à maintenant.

# Scaled Dot-Product Attention

- Pour la self-attention qui se déroule dans l'encodeur, les requêtes, les clés et les valeurs proviennent de la séquence des inputs.
- Pour la self-attention qui se déroule dans décodeur, les requêtes, les clés et les valeurs proviennent de la séquence des mots décodés jusqu'à maintenant.
- Pour l'attention qui se déroule dans décodeur, les requêtes proviennent des outputs de l'encodeur, et les clés et les valeurs proviennent de la séquence des mots décodés jusqu'à maintenant.

# Scaled Dot-Product Attention

- Pour la self-attention qui se déroule dans l'encodeur, les requêtes, les clés et les valeurs proviennent de la séquence des inputs.
- Pour la self-attention qui se déroule dans décodeur, les requêtes, les clés et les valeurs proviennent de la séquence des mots décodés jusqu'à maintenant.
- Pour l'attention qui se déroule dans décodeur, les requêtes proviennent des outputs de l'encodeur, et les clés et les valeurs proviennent de la séquence des mots décodés jusqu'à maintenant.

# Scaled Dot-Product Attention

$$\text{Attention}(Q, K, T) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

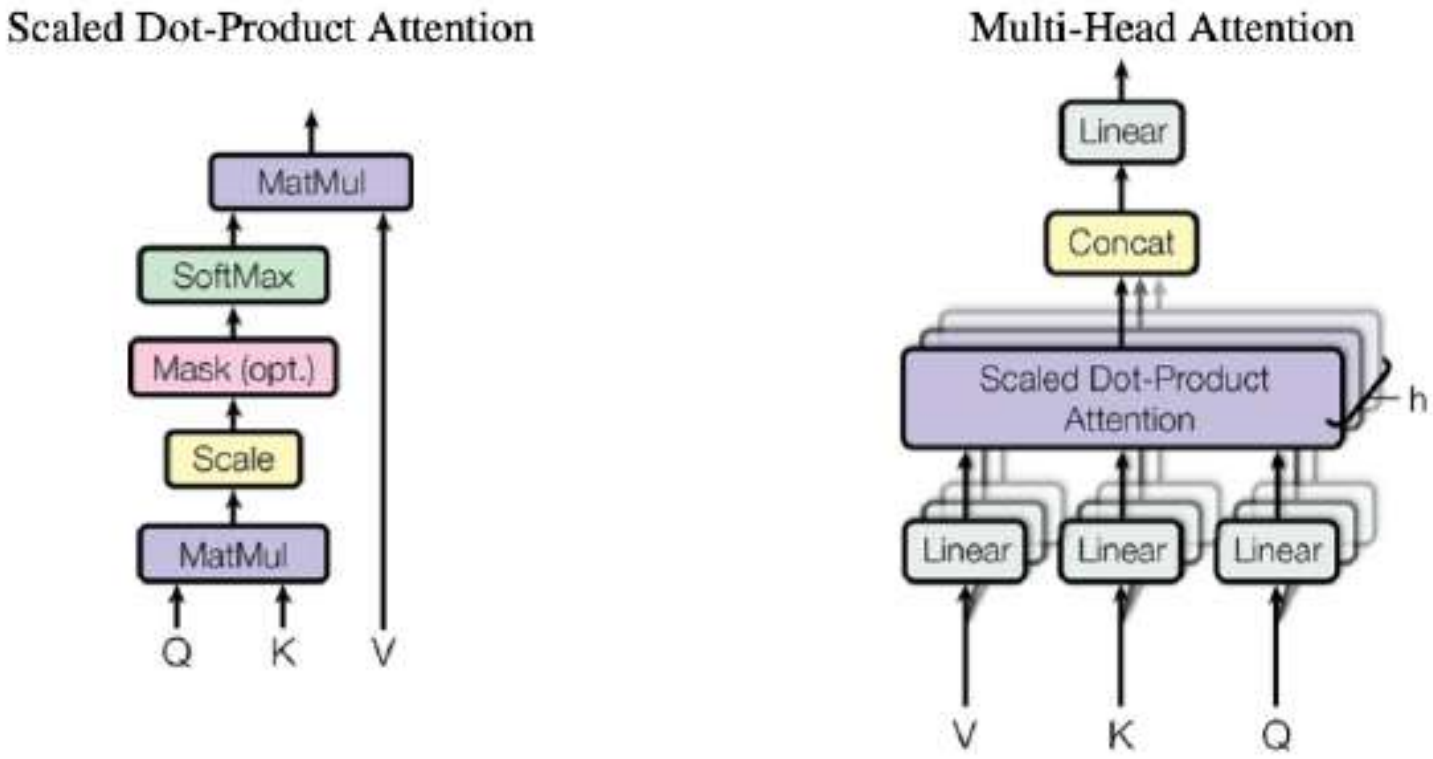


Figure taken from [Vaswani et al., 2017].

# Scaled Dot-Product Attention

$$\text{Attention}(Q, K, T) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

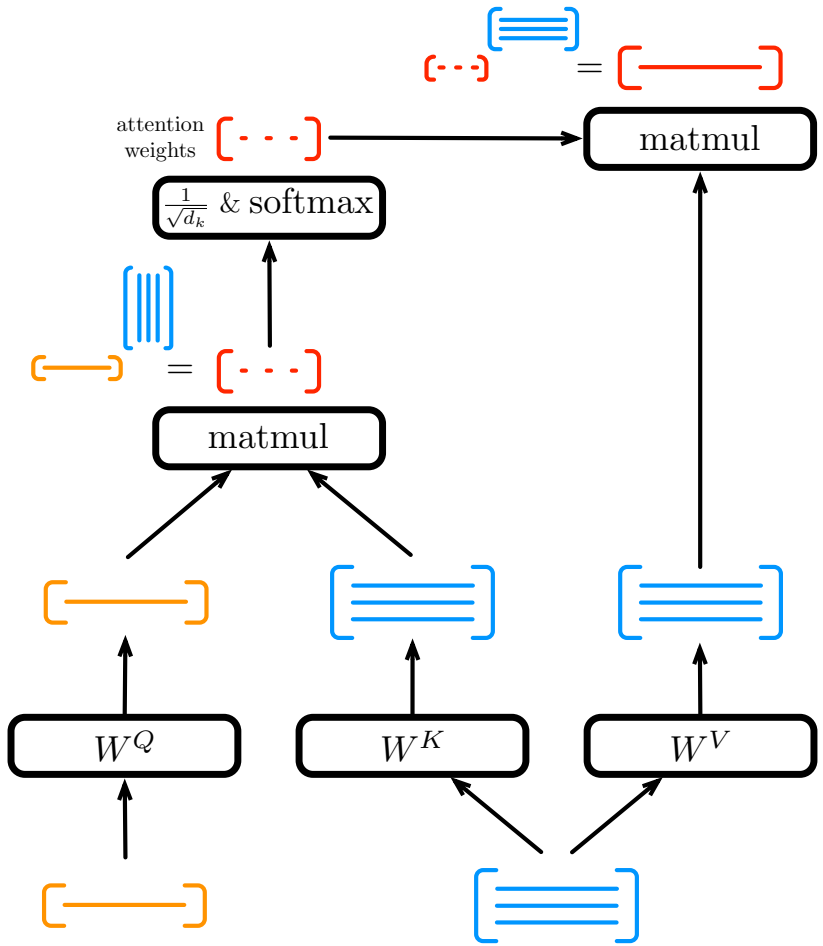

# Scaled Dot-Product Attention

- On peut appliquer le processus à plusieurs *queries* en parallèle.

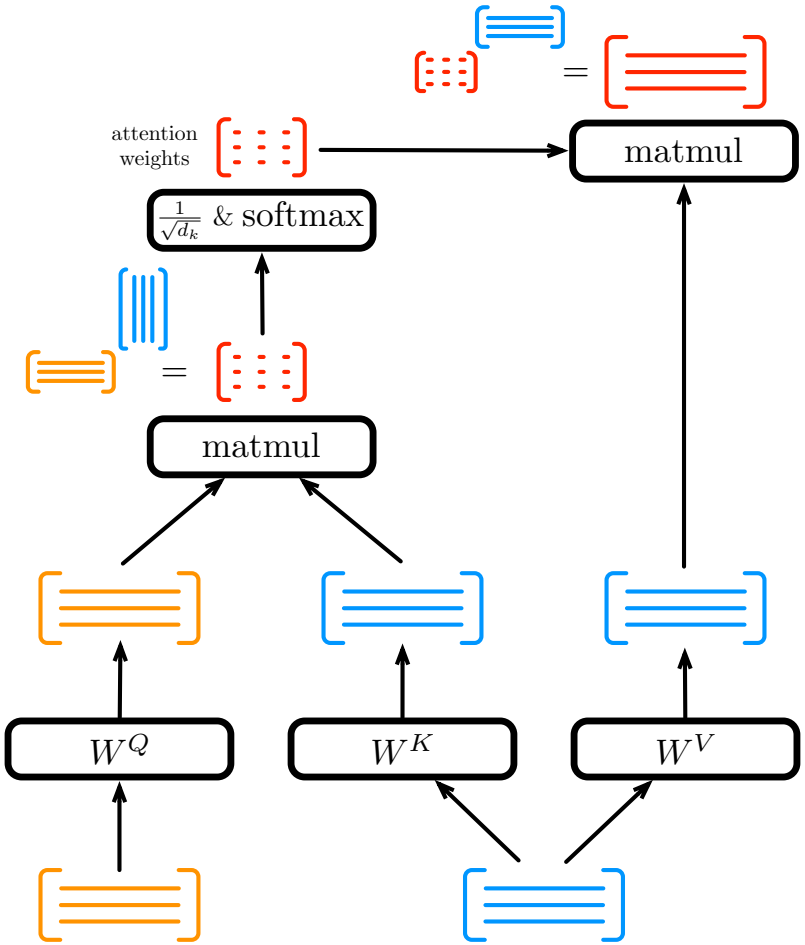

# Self-Attention

- Lorsque les *queries* proviennent de la même sequence que les *keys* et les *values*, on parle de **self-attention**.

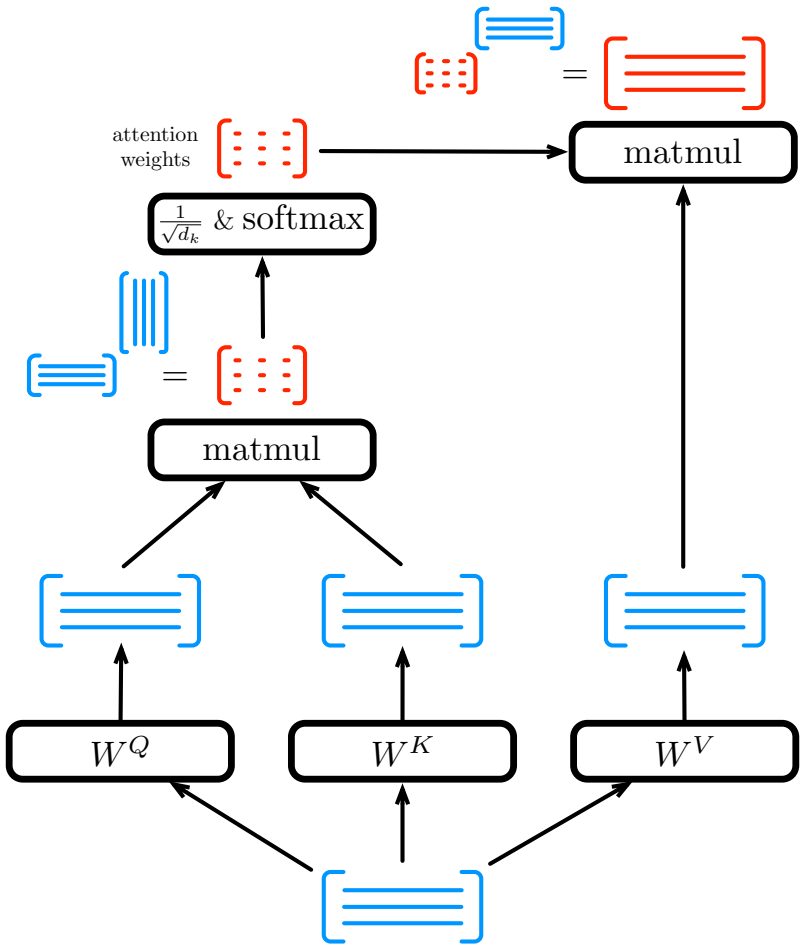

# Masked Self-Attention

- Lorsque on interdit aux *queries* de porter de l'attention sur les éléments suivants de la sequence, on parle de **masked self-attention**.

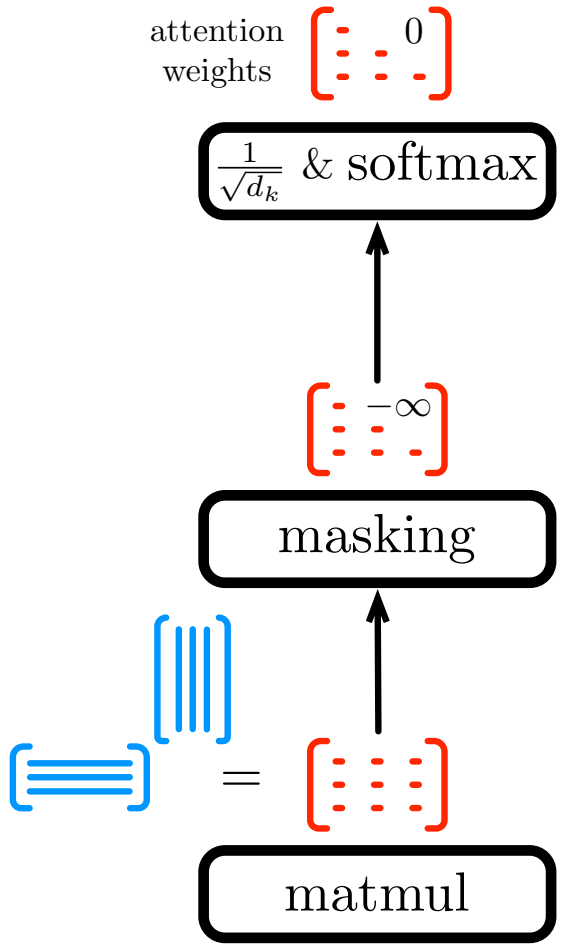

# Masked Self-Attention

- Lorsque on interdit aux *queries* de porter de l'attention sur les éléments suivants de la sequence, on parle de **masked self-attention**.

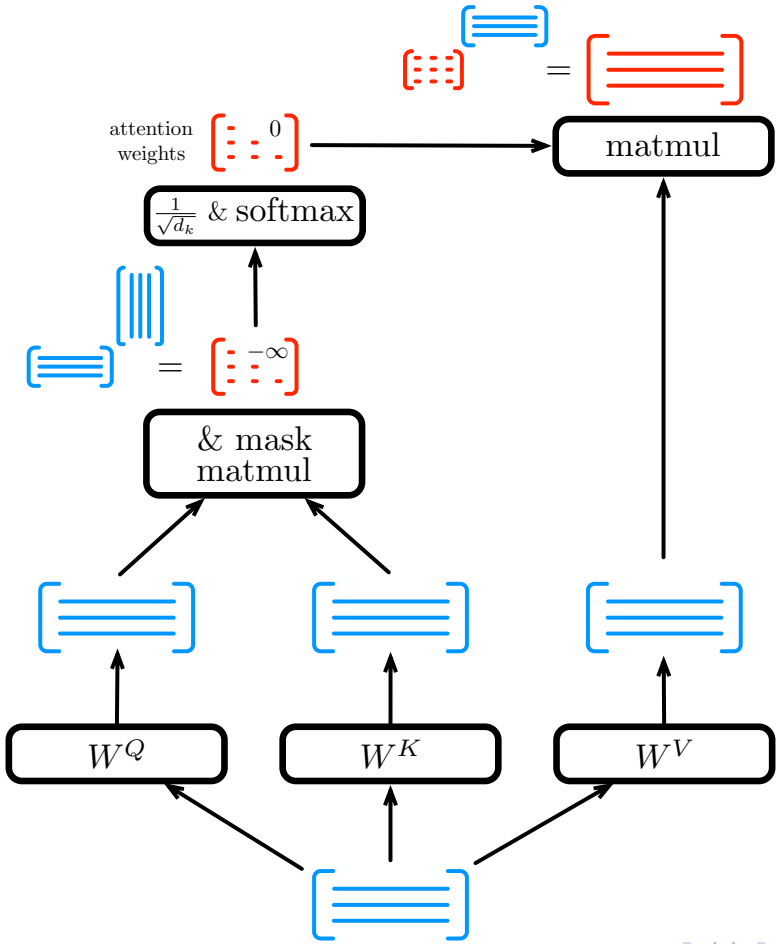

# Encodeur-décodeur

- L'**encodeur** utilise de la **self-attention** pour "embedder" les inputs.
- Le **décodeur** procède en 2 étapes:

1. **Masked self-attention** pour "embedder" les mots décodés jusqu'à maintenant.
2. **Attention** pour générer le nouveau mot à décoder: la query est l'embedding du dernier mot décodé et les keys et les values sont les embeddings des inputs.

# Encodeur-décodeur

- L'**encodeur** utilise de la **self-attention** pour "embedder" les inputs.
- Le **décodeur** procède en 2 étapes:

1. **Masked self-attention** pour "embedder" les mots décodés jusqu'à maintenant.
2. **Attention** pour générer le nouveau mot à décoder: la query est l'embedding du dernier mot décodé et les keys et les values sont les embeddings des inputs.

# Encodeur-décodeur

- L'**encodeur** utilise de la **self-attention** pour "embedder" les inputs.
- Le **décodeur** procède en 2 étapes:

1. **Masked self-attention** pour "embedder" les mots décodés jusqu'à maintenant.
2. **Attention** pour générer le nouveau mot à décoder: la query est l'embedding du dernier mot décodé et les keys et les values sont les embeddings des inputs.

# Encodeur-décodeur

- L'**encodeur** utilise de la **self-attention** pour "embedder" les inputs.
- Le **décodeur** procède en 2 étapes:

1. **Masked self-attention** pour "embedder" les mots décodés jusqu'à maintenant.
2. **Attention** pour générer le nouveau mot à décoder: la query est l'embedding du dernier mot décodé et les keys et les values sont les embeddings des inputs.

# Encodeur-décodeur: training

- Le Transformer est entraîné en mode *teacher-forcing*.
- La vraie phase d'output (target sequence) est passée au décodeur dans le but d'être apprise.
- Le décodeur traite la séquence d'input et la vraie phase d'output *en parallèle*, calcule la loss entre prédictions et réalités, et update ses paramètres par backpropagation.
- **Avantages:** parallèlisation et non-accumulation des erreurs lors du processus de décodage.

# Encodeur-décodeur: training

- Le Transformer est entraîné en mode *teacher-forcing*.
- La vraie phase d'output (target sequence) est passée au décodeur dans le but d'être apprise.
- Le décodeur traite la séquence d'input et la vraie phase d'output *en parallèle*, calcule la loss entre prédictions et réalités, et update ses paramètres par backpropagation.
- **Avantages:** parallèlisation et non-accumulation des erreurs lors du processus de décodage.

# Encodeur-décodeur: training

- Le Transformer est entraîné en mode *teacher-forcing*.
- La vraie phase d'output (target sequence) est passée au décodeur dans le but d'être apprise.
- Le décodeur traite la séquence d'input et la vraie phase d'output *en parallèle*, calcule la loss entre prédictions et réalités, et update ses paramètres par backpropagation.
- **Avantages:** parallèlisation et non-accumulation des erreurs lors du processus de décodage.

# Encodeur-décodeur: training

- Le Transformer est entraîné en mode *teacher-forcing*.
- La vraie phase d'output (target sequence) est passée au décodeur dans le but d'être apprise.
- Le décodeur traite la séquence d'input et la vraie phase d'output *en parallèle*, calcule la loss entre prédictions et réalités, et update ses paramètres par backpropagation.
- **Avantages:** parallèlisation et non-accumulation des erreurs lors du processus de décodage.

# Encodeur-décodeur: training

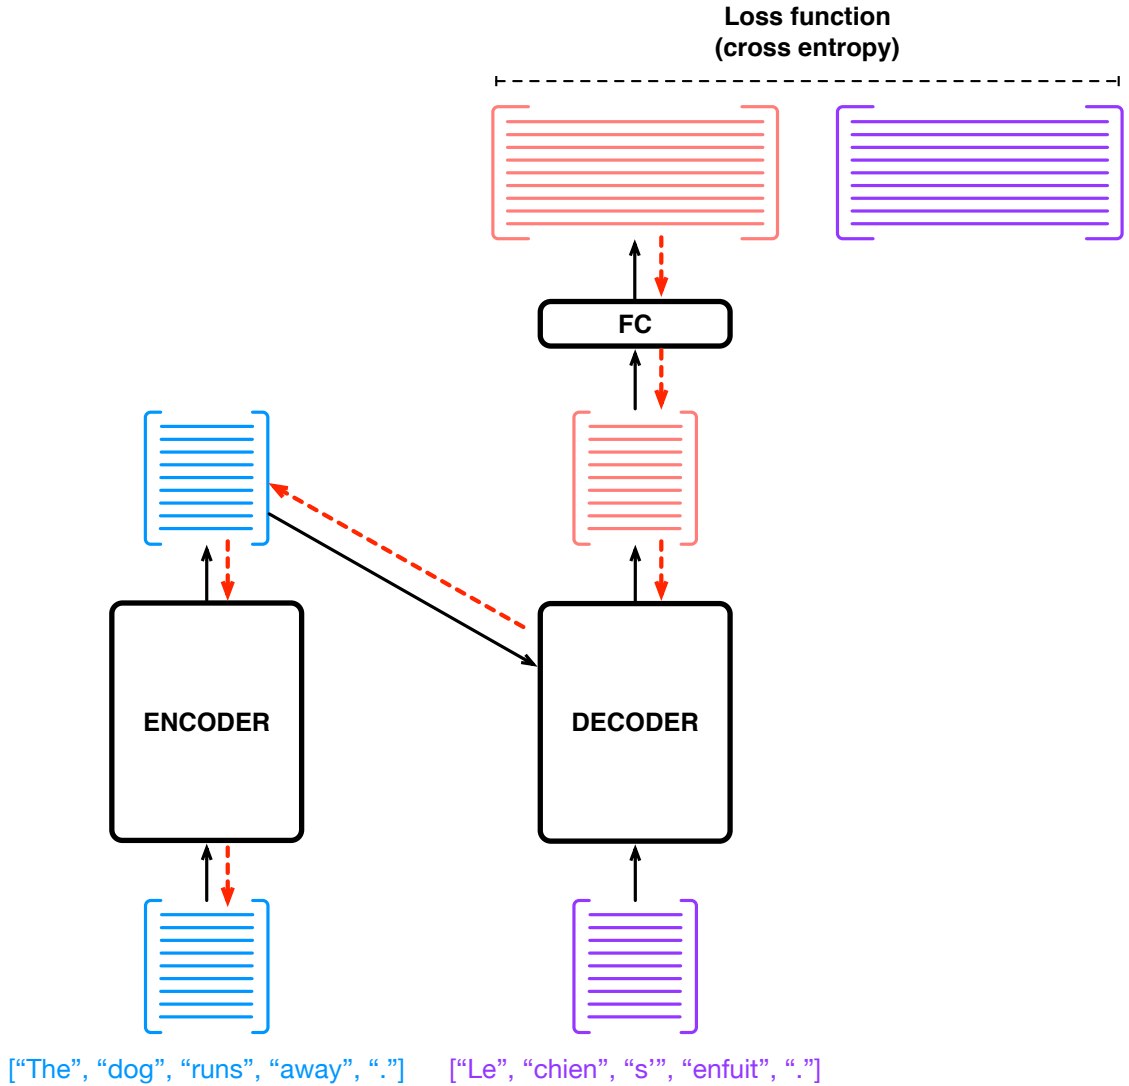

# Encodeur-décodeur: inférence

- Pour une séquence d'inputs donnée, le Transformer produit une séquence d'outputs *pas à pas*.
- À chaque étape, la séquence d'inputs et la séquence d'outputs décodées jusqu'à maintenant sont passées au décodeur.
- Le décodeur produit alors un nouveau mot qui est appondu à la séquence d'outputs décodées jusqu'à maintenant.
- La séquence d'inputs et cette nouvelle séquence d'outputs décodées jusqu'à maintenant sont re-passées au décodeur qui produit alors un nouveau mot.
- Etc.

# Encodeur-décodeur: inférence

- Pour une séquence d'inputs donnée, le Transformer produit une séquence d'outputs *pas à pas*.
- À chaque étape, la séquence d'inputs et la séquence d'outputs décodées jusqu'à maintenant sont passées au décodeur.
- Le décodeur produit alors un nouveau mot qui est appondu à la séquence d'outputs décodées jusqu'à maintenant.
- La séquence d'inputs et cette nouvelle séquence d'outputs décodées jusqu'à maintenant sont re-passées au décodeur qui produit alors un nouveau mot.
- Etc.

# Encodeur-décodeur: inférence

- Pour une séquence d'inputs donnée, le Transformer produit une séquence d'outputs *pas à pas*.
- À chaque étape, la séquence d'inputs et la séquence d'outputs décodées jusqu'à maintenant sont passées au décodeur.
- Le décodeur produit alors un nouveau mot qui est appondu à la séquence d'outputs décodées jusqu'à maintenant.
- La séquence d'inputs et cette nouvelle séquence d'outputs décodées jusqu'à maintenant sont re-passées au décodeur qui produit alors un nouveau mot.
- Etc.

# Encodeur-décodeur: inférence

- Pour une séquence d'inputs donnée, le Transformer produit une séquence d'outputs *pas à pas*.
- À chaque étape, la séquence d'inputs et la séquence d'outputs décodées jusqu'à maintenant sont passées au décodeur.
- Le décodeur produit alors un nouveau mot qui est appondu à la séquence d'outputs décodées jusqu'à maintenant.
- La séquence d'inputs et cette nouvelle séquence d'outputs décodées jusqu'à maintenant sont re-passées au décodeur qui produit alors un nouveau mot.
- Etc.

# Encodeur-décodeur: inférence

- Pour une séquence d'inputs donnée, le Transformer produit une séquence d'outputs *pas à pas*.
- À chaque étape, la séquence d'inputs et la séquence d'outputs décodées jusqu'à maintenant sont passées au décodeur.
- Le décodeur produit alors un nouveau mot qui est appondu à la séquence d'outputs décodées jusqu'à maintenant.
- La séquence d'inputs et cette nouvelle séquence d'outputs décodées jusqu'à maintenant sont re-passées au décodeur qui produit alors un nouveau mot.
- Etc.

# Encodeur-décodeur: inférence

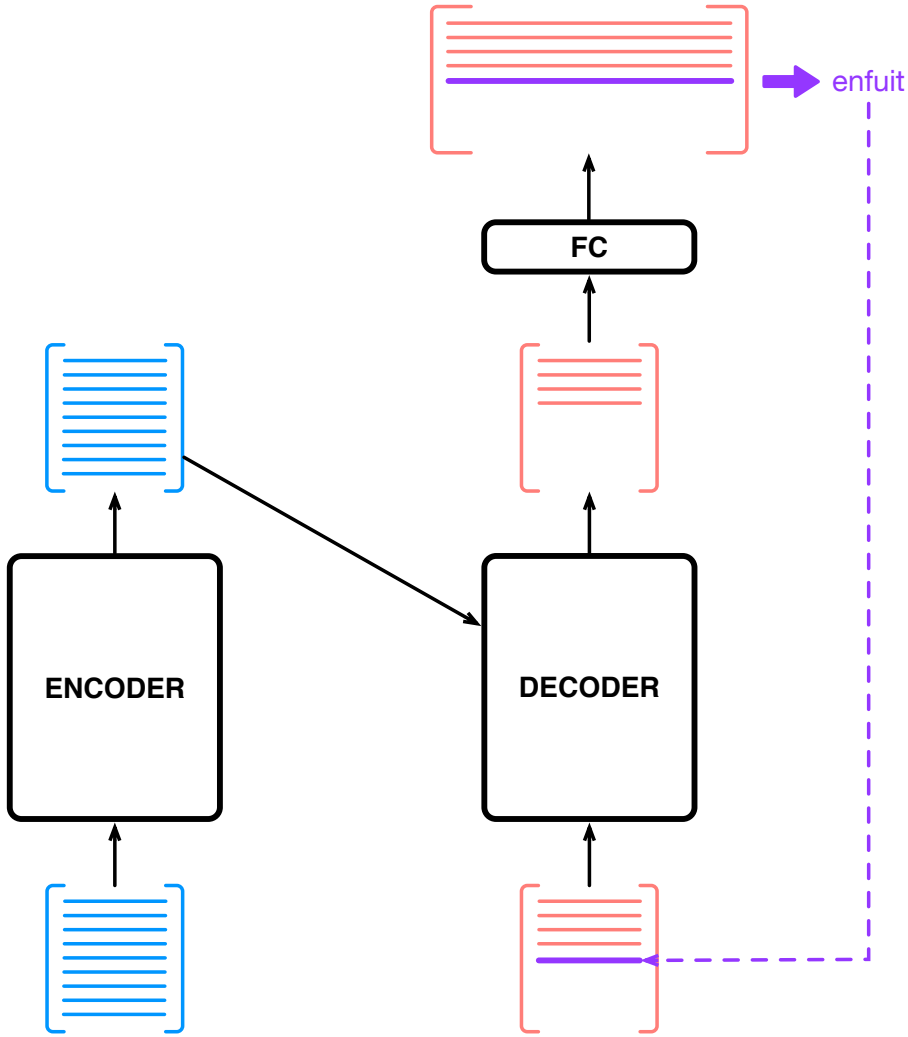

# Bibliographie


Alammar, J. (2018).
The illustrated transformer.


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017).
Attention is all you need.
In Guyon, I., von Luxburg, U., Bengio, S., Wallach, H. M., Fergus, R., Vishwanathan, S. V. N., and Garnett, R., editors, *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, pages 5998–6008.